

report

2026-03-11


1 月版本的核心问题

- 没做平行世界，影响归因分析
- 冲击系数固定：正 or 负面对个体的冲击幅度几乎保持为常数，不因不同个体/事件等而改变
- 问卷太简单
- 机制闭环不完整：状态变化对后续行为路径影响弱
- 触发偏概率注入

初步改造

- 平行世界
- 状态更新改为动态变化（环境 + 个体特征 + 当前 step 共同决定）
- 问卷扩展为更多维 (acceptance / trust / helplessness / behavior)
- 状态变化影响后续行为路径
- 触发改为多段判定 + 审计日志，降低无依据触发

初步改造示意图



触发机制完善

- ① 抽取当步信号: `step_outcome / consumed_time / failure_pressure / success_support`
- ② 数字语境检测: 检测 `action or status or intention`
- ③ llm 主导判定: 产出数字性 + 场景 + 置信度
- ④ 规则兜底: `first gate + status gate`
- ⑤ 回退: 上述均未命中时才进入

每次 attempt 都写入 `decision_json`, 存放路径来源、置信度、放行理由、`roll`、`event_total_prob`, 便于审查。

Hybrid 校准与历史惯性

- Hybrid 不让 LLM 直接决定是否数字，而是输出倍率：
`risk_mult/protect_mult/neg_impact_mult/pos_impact_mult`
- 系统按 α 融合 rule 与 LLM，低置信/跳变过大自动回退 rule
- attempt-hazard 引入短期记忆：近期事件密度、失败压力变化、refractory 衰减

$$z_{total} = 0.45z_{prior} + 0.55z_{context} + offset - refractory + 0.16\Delta fail + 0.08\Delta mean$$

$$p_{total} = \sigma(z_{total}), \quad p^{-} = p_{total} \cdot r_{neg}, \quad p^{+} = p_{total}(1 - r_{neg})$$

Prompt Engineering 改造前后对比

指标	改造前	改造后
Hybrid 生效次数	0 (均回退为 rule)	126 (均为 hybrid)
非数字事件占比	$23/53 = 43.4\%$	$0/83 = 0\%$
高质量触发样本	$27/53 = 50.9\%$	$78/83 = 94\%$

- 样本纯度与可解释性显著提升。

实验配置与规模

- Group ID: digital_friction_parallel_20260311_002952
- 世界: A=baseline_low_friction, B=high_friction_low_assist, C=low_friction_high_assist
- 配对: 4 组 seed (101-104), 每组 A/B/C 同 seed
- 总子实验数: $4 \times 3 = 12$
- 每次子实验: 6 个 agents, 单阶段 1 天, 30 分钟步长
- 运行总时长约 7.4 小时 (平均每子实验约 37 分钟)

行为指标结果 (4 组 seed 平均)

World	AttemptRate	EmitGivenAttempt	NegShare
A Baseline	0.3637	0.2608	0.2640
B High Friction	0.3429	0.5727	0.5402
C Low Friction + Assist	0.2856	0.1505	0.1116

心理状态变化（末值-初值，4 组 seed 平均）

World	Helplessness Δ	Trust Δ	Avoidance Δ
A Baseline	-5.58	+1.73	-2.19
B High Friction	+33.08	-40.61	+29.86
C Low Friction + Assist	-8.50	+7.37	-4.35

Survey 扩展指标（末轮-首轮，4 组 seed 平均）

指标	A Baseline	B High Friction	C Low Friction + Assist
TechAcceptance Δ	+3.13	+0.63	-2.92
SurveyTrust Δ	-0.83	+0.63	-4.79
SurveyAvoidance Δ	+0.42	-3.33	-4.38
HelplessIndex Δ	+3.13	+0.31	-1.56
WithdrawalIndex Δ	-1.81	+5.90	-0.35
DelayOnline Δ	-1.88	+5.00	-4.38
ProxyReliance Δ	-6.04	+8.33	+1.67
OfflineSwitch Δ	+2.50	+4.38	+1.67

注：本页由 agent_survey 两轮问卷直接计算（末轮-首轮），用于补充展示。

Survey 扩展指标配对差值 (B-A, C-A)

指标	B-A 均值差	C-A 均值差
TechAcceptance Δ	-2.50	-6.04
SurveyTrust Δ	+1.46	-3.96
SurveyAvoidance Δ	-3.75	-4.79
HelplessIndex Δ	-2.81	-4.69
WithdrawalIndex Δ	+7.71	+1.46
DelayOnline Δ	+6.88	-2.50
ProxyReliance Δ	+14.38	+7.71
OfflineSwitch Δ	+1.88	-0.83

配对差值统计 (B-A, C-A)

指标	B-A 均值差	C-A 均值差
NegShare	+0.2762	-0.1524
Helplessness Δ	+38.66	-2.92
Trust Δ	-42.33	+5.64
Avoidance Δ	+32.06	-2.15

下一步计划

- 增加子实验次数
- 对于参数，做敏感性分析（步长、 α 、hazard 窗口）
- 进一步校准初始化与冲击系数（这个感觉很难。。）

请老师批评指正 orz