

Digital Friction 中 Helplessness 机制的初步形式化

2026-04-20

相关论文如何理解 Scope

Learned Helplessness in Humans: Critique and Reformulation

Lyn Y. Abramson, Martin E. P. Seligman, John D. Teasdale

- Abramson, Seligman, and Teasdale (1978) 认为, 人类的 helplessness 不能只看其结果是否不可控, 更关键的是人怎样解释这次 noncontingency
- **scope 决定 generality**, 如果个体把失败理解成“这一类事我都不行”, 无助就更容易从当前任务扩散出去

Situation Similarity and the Generalization of Learned Helplessness

Marika Tiggemann, A. H. Winefield

- Tiggemann and Winefield (1978) 发现, learned helplessness 在相似任务上明显出现, 但在不相似的任务上几乎不泛化
- 这说明 helplessness 的跨任务扩散不是无边界的, 而是受场景相似度约束

Failure → Attribution Scope → Task-Family Spillover

Gaussian 为什么被选中作为 scope 的形式化更新方式

- 如果一次数字事件失败的 Scope 归因也会扩散，那它应该优先影响相似任务，而不是平均地扩散到所有任务。由于目前缺少针对 Scope 的成熟形式化研究，这里借鉴了人类泛化机制中的距离衰减写法。
- Lucas et al. (2015) 和 Wu et al. (2018) 在人类泛化建模里，正是用高斯过程来表达这种“按距离衰减”的关系
- Lee et al. (2021) 进一步指出，泛化梯度常接近高斯形状；按心理距离缩放后，又和 Shepard 的指数衰减规律一致，所以 Gaussian 在这里既符合直觉，也有认知建模上的理论支撑

区分：我们借用的是距离衰减形式，不是把 scope 和人类泛化当成同一个变量。

人类泛化机制：人会把一次经验推广到相似情境中，而且这种推广会随着相似度下降而减弱。

Gaussian Kernel 版本

$$A_t = \beta U_t a_t$$

$$d(i, j) = 1 - S_{ij}$$

$$w_{ij} = \exp\left(-\frac{d(i, j)^2}{2\sigma(g_t)^2}\right), \quad j \neq i$$


$$\hat{w}_{ij} = \frac{w_{ij}}{\sum_{k \neq i} w_{ik}}$$

$$\Delta SE_{j,t}^{\text{spill}} = -A_t \hat{w}_{ij}$$

标注：当前代码里， a_t 是 LLM 输出的 scope amplitude； σ 先固定； $\hat{w}_{ij}$ 是归一化后的 Gaussian 权重。

在当前实验中如何加入

当前实验里的流程



当前实现的版本

单参数 Gaussian spillover

- LLM 只输出 scope amplitude
- σ 先固定, 不让 LLM 参与; 后续再决定是否加入可变 σ
- Gaussian 权重会做归一化

当前代码使用的 fixed similarity matrix

	L	A	P	H
L	1.0	0.3	0.8	0.2
A	0.3	1.0	0.2	0.7
P	0.8	0.2	1.0	0.2
H	0.2	0.7	0.2	1.0

L = 登录验证, A = 挂号预约

P = 支付结算, H = 健康信息查询

直觉上, L-P 更近, A-H 更近, 跨组传播更弱。

A Bayesian formulation of behavioral control

- **第一层：outcome entropy**。看一个动作会不会稳定导向少数结果，如果越稳定，控制就越高（更偏向于单个动作的稳定性）
- **第二层：controllably achievable outcomes**。看不同动作是不是能稳定带来不同结果，而不是多个动作的情况下，最后结果差不多（但这一层还不涉及这些结果是否真正有价值）
- **第三层：controllably achievable reinforcement**。最关键的是那些对个体有价值的结果里，有多少是可以通过行为可靠控制的

论文最后更看重的是第三层，因为它更接近 helplessness 的心理实质：

我在乎的结果，到底是不是受我行为控制？

A Bayesian formulation of behavioral control

- 论文形式化的是个体对环境可控性的先验信念，即 **controllability prior**
- 一旦这种先验变得悲观，它就会进入后续任务，影响 action-outcome 预测、动作价值差异和探索意愿
- 被动、少尝试和更容易放弃，更接近于低 controllability prior 在新任务中的行为后果

过去经验 → 可控性先验 → 当前任务中的结果预测与动作价值判断 → 更被动的行为

核心预测分布

$$P(r \mid N_t, a, \alpha) = \frac{\alpha}{\alpha + N_t(a)} B(r) + \frac{1}{\alpha + N_t(a)} N_t(r, a)$$

- 这个式子表示：如果现在再做一次动作 a ，结果 r 的预测概率是多少
- 预测不是只由眼前经验决定，也不是只由原有先验决定，而是由两者共同决定
- $B(r)$ ：还没什么经验时，对结果 r 的默认预期
- $N_t(r, a)$ 和 $N_t(a)$ ：到目前为止，动作 a 一共试了多少次，其中结果 r 出现了多少次
- α ：先验权重； α 越大，少量新经验越难立刻推翻原来的判断

怎么借到我们的更新主线里

最推荐借的不是原公式细节，而是结构

Outcome $\rightarrow$ evidence about control $\rightarrow C_t \rightarrow H_t$

一个适合我们实验的简化写法

$$C_{f,t} = \frac{a_{f,t}}{a_{f,t} + b_{f,t}}$$

$$a_{f,t+1} = \rho a_{f,t} + \eta e_t \quad b_{f,t+1} = \rho b_{f,t} + \eta(1 - e_t)$$

$$e_t = 1 - \frac{U_t}{2}$$

$$\Delta H_t = \beta U_t (1 - C_{f,t})$$

最通俗的理解

- C_t : agent 当前还相不相信 “继续努力有用”
- a_t : 累计的可控证据
- b_t : 累计的不可控证据
- U_t : 这次事件的 uncontrollability

和当前代码的关系

- 现在先不必推翻现有系统
- 可以把当前实现看成这一思路的近似版
- `task_self_efficacy` 更像长期的 control belief proxy
- `felt_control` 更像当前情境里的局部控制感
- `controllable_success_memory` 更像支持 control belief 的正向证据