

对我们的启示和改进指导

文档目的

这份文档专门回答一个问题：

这篇 **learned helplessness / learned controllability** 综述，对 **digital_friction_mvp** 里的 **helplessness update** 到底意味着什么？

一句话结论

这篇论文支持你们把长期 helplessness 的更新机制，从“按事件结果直接加减”改成“按主观不可控感和行动有效感来更新”。

也就是说：

- 失败不是核心
- 摩擦不是核心
- 核心是：任务之后，agent 是否形成了“努力没用”的解释

论文中最能直接支持机制改造的证据

证据 1：learned helplessness 的关键是“结果与行动无关”

论文结论部分明确说：

- in learned helplessness an organism learns that outcomes are independent of their actions
- in humans this involves a learned attitude of decreased motivation to exert effort

这意味着：

- helplessness 的更新逻辑不能只按 **failure_after_attempt +4**
- 更应该看“这次事件是不是让他更相信努力无效”

证据 2：learned helplessness 来自 repeated unsuccessful attempts under uncontrollability

论文在 learned helplessness 小节里强调：

- prolonged exposure to uncontrollable stressors
- followed by repeated unsuccessful attempts to cope
- may lead to helplessness

这说明：

- repeated failure 当然重要
- 但 failure 只有在 high uncontrollability 条件下，才更像 helplessness 的形成

证据 3：learned controllability 同样来自学习

论文强调：

- controllability may be developed through a learning process
- establishing a causal link between voluntary actions and desired outcomes enhances subjective perception of control

这意味着：

- 成功不只是“把 helplessness 减一点”
- 更重要的是：成功有没有恢复“行动和结果是连着的”这种体验

证据 4：过去的可控经验会产生 immunization

论文明确说：

- previous experiences of control may reduce susceptibility to helplessness
- providing immunization against stressful conditions

这意味着：

- 更新机制不能只累积负面
- 正面的 controllable success 也应该形成长期保护

当前代码机制和论文的差距

当前长期 helplessness 的主更新更接近：

- outcome label
- consecutive failures
- perceived_uncontrollability
- support buffer

这比“纯结果记分”已经好很多，但和综述的理论还有三处差距。

差距 1：outcome 的直接权重仍然偏大

现在容易形成一种解释：

- 失败 = helplessness 涨
- 成功 = helplessness 降

而综述真正支持的是：

- failure 不是根
- “是否学到 effort is ineffective”才是根

差距 2：support 仍然太像直接缓冲项

从 learned controllability 的角度看，support 真正有用，不是因为它“替你减分”，而是因为它能帮助个体重新建立 action-outcome contingency。

所以：

- 直接 buffer 不是最好的解释
- 恢复 controllability 才是更好的解释

差距 3：可控成功的保护作用还不够理论化

现在 success_self / success_with_help 有差别，但还没有充分体现：

- 自主可控成功是长期保护因素
- 它能降低未来进入 helplessness 的敏感性

机制改造原则

原则 1：长期 helplessness 主更新项应是 uncontrollability，不是 outcome

建议把 outcome label 理解成：

- 一个事件类别
- 一个初级信号

而不是长期 helplessness 的主导因素。

真正主导项应是：

- perceived_uncontrollability
- felt_control
- repeated uncontrollable failure

原则 2：把 repeated failure 改写成 repeated uncontrollable failure

不是所有失败都同样危险。

例如：

- 高摩擦下失败，但 agent 仍觉得“再换种方法有机会”
- 和
- 高摩擦下失败，并且 agent 觉得“怎么做都没用”

这两种 failure 都是 failure，但对 helplessness 的意义完全不同。

建议：

- 连败项应与 perceived_uncontrollability 绑定
- 如果 repeated failure 但 control 还没塌，涨幅应更温和

原则 3：把 success 理解成“controllability evidence”

建议把成功分成不同质量：

高质量成功

- success_self
- 结束连败后的自我成功

- 在较高摩擦任务中自己成功

这些都更像“我能控制结果”的证据，应对 helplessness 有更强修复作用。

中等质量成功

- `success_with_help`

这类成功不应一概等于高质量恢复。

如果帮助只是代做，恢复的其实不是 controllability，而只是任务完成。

因此建议：

- `success_with_help` 的恢复力度取决于 `expected_help_effectiveness`
- 或取决于 support 是否能保留 agency

原则 4：把 support 从“回血项”改成“controllability 恢复项”

论文并不直接研究 support，但它对你们 support 机制有清楚的间接启发：

- support 有价值，不是因为它直接减少 helplessness
- 而是因为它可能帮助恢复“行动有效”的主观体验

所以建议 support 的主要路径改成：

- support -> 提高 felt_control
- support -> 提高 expected_help_effectiveness
- support -> 提高 self-efficacy
- 然后这些变量再影响 helplessness

推荐的修改方向

方向 A：长期 helplessness 更新公式改成“控制主导”

建议从：

```
delta_h
= base(outcome)
+ repetition
+ uncontrollability
- support
```

改成：

```
delta_h
= weak_event_signal
+ uncontrollable_failure_term
+ low_control_term
+ low_efficacy_term
```

- controllable_success_term
- small_support_term

其中：

- uncontrollable_failure_term 是主项
- controllable_success_term 是对 learned controllability 的体现

方向 B：为 controllable success 增加长期保护效应

建议你们后续考虑增加一个保护性记忆量，例如：

- control_mastery_memory
- 或 controllable_success_streak

作用：

- 高质量成功累积后
- 未来遇到高摩擦任务时
- helplessness 的增长敏感性下降

这正对应综述里说的 immunization。

方向 C：避免把所有 avoid 都解释为 helplessness

从 learned helplessness 理论看，真正重要的是：

- avoid 是不是源于“努力无效感”

所以建议：

- avoid_without_attempt 只有在低控制 + 连续负面经验条件下，才明显推高 helplessness
- 否则它可能只是低价值判断、疲惫、懒得做或任务替代选择

方向 D：把长期恢复机制写清楚

建议在机制说明中明确区分：

recovery of task completion

任务完成了

recovery of controllability

个体重新体验到“我的行动有效”

第二种才是对 helplessness 最关键的恢复。

最小可执行改造建议

如果暂时不想大改结构，建议先做下面三步。

第一步

降低 outcome label 的直接 base 权重。

第二步

让 `perceived_uncontrollability` 和 `felt_control` 成为长期 helplessness update 的主项。

第三步

对 `success_self` 和 `ended_failure_streak` 给更明确的“controllability recovery”解释和更强权重。

可直接用于汇报/文档的表述

“根据 learned helplessness / learned controllability 综述，我们将 helplessness 理解为对‘行动与结果脱钩’的学习结果，而非对负面事件本身的简单累积。因此，更新机制应主要追踪 repeated uncontrollable failure 所引发的主观不可控感，而不是按 success/failure 标签直接记分。与此同时，能够重建行动有效感的 controllable success 应被视为 learned controllability 的证据，并对未来 helplessness 的增长具有保护作用。”

最后一句判断

这篇论文最重要的启发不是“失败加多少分，成功减多少分”，而是：

你们真正要更新的，是 agent 对“我努力是否有用”的学习结果。

只要这点在机制上站住了，后面的参数调整才有理论根。